

## PROPUESTA DE PROYECTO DE MACHINE LEARNING

Título del Proyecto:

- Predicción de resultados y perfiles competitivos en la Copa Mundial mediante Aprendizaje Supervisado y No Supervisado.

Nombre(s) del/los estudiantes(s):

- Ronald Samir Molinares Sanabria
- María Fernanda Sogamoso González

Asignatura:

- ELECTIVA II - MACHINE LEARNING APLICADO

Docente:

- Viviana Alexandra Villanueva Cipagauta

Universidad / Facultad / Programa:

- Universidad Pedagógica y Tecnológica de Colombia / Facultad de Ingeniería, Escuela de Ingeniería de Sistemas e Informática / Ingeniería de Sistemas y Computación

Fecha:

- 20/04/2026

Dataset:

- <https://www.kaggle.com/datasets/piterfm/fifa-football-world-cup>

## 1. Título del proyecto

Predicción de resultados y perfiles competitivos en la Copa Mundial mediante Aprendizaje Supervisado y No Supervisado.

## 2. Planteamiento del problema

En una sala de operaciones sin ventanas ubicada en el centro financiero de una ciudad de Colombia, un equipo de analistas de una reconocida casa de apuestas deportivas aguarda, noche tras noche, el pitazo inicial de cada partido mundialista. Sobre sus pantallas se despliegan cuotas, probabilidades y proyecciones que, en cuestión de minutos, serán consultadas por millones de apostadores alrededor del mundo. La presión es inmensa: una cuota mal calculada puede representar pérdidas millonarias; una predicción certera, en cambio, es la diferencia entre la sostenibilidad del negocio y el colapso financiero. Este escenario, lejos de ser ficticio, describe con precisión la realidad que enfrenta la industria global de apuestas deportivas cuando llega la Copa Mundial de la FIFA.

El torneo mundialista de fútbol es, sin lugar a dudas, el evento deportivo de mayor convocatoria en el planeta. Con una audiencia acumulada que supera los cinco mil millones de espectadores en sus ediciones recientes, la Copa del Mundo no solo moviliza pasiones colectivas, sino también volúmenes extraordinarios de capital en los mercados de apuestas. Se estima que durante cada edición del torneo el mercado global de apuestas deportivas procesa cientos de miles de millones de dólares en transacciones, lo que convierte cada resultado en una variable económica de primer orden. En este contexto, la capacidad de anticipar con precisión el desenlace de un partido no es un ejercicio académico menor: es una necesidad operativa de alta rentabilidad.

Sin embargo, predecir el resultado de un partido de fútbol es, por naturaleza, una tarea extraordinariamente compleja. A diferencia de otros eventos deportivos más lineales, el fútbol combina habilidad técnica, estado físico, táctica, condiciones del entorno, factores psicológicos e incluso elementos de azar que desafían cualquier modelo determinista. Una selección considerada amplia favorita puede caer ante un equipo de menor trayectoria; una racha de victorias puede interrumpirse de manera abrupta; y el resultado de un partido puede depender de un penalti, una lesión o una decisión arbitral en los últimos minutos. Esta alta variabilidad hace que los métodos tradicionales de predicción, basados en intuición experta o en estadísticas simples como la diferencia de goles o el historial de enfrentamientos directos, resulten insuficientes para capturar la verdadera complejidad del fenómeno.

Ante esta realidad, el Machine Learning emerge como una herramienta de alto valor estratégico. A diferencia del análisis estadístico convencional, los algoritmos de aprendizaje automático tienen la capacidad de identificar patrones no lineales en grandes volúmenes de

datos históricos, aprender de regularidades ocultas y generar predicciones probabilísticas fundamentadas en evidencia empírica. Una casa de apuestas que incorpore modelos supervisados de clasificación en su proceso de construcción de cuotas cuenta con una ventaja competitiva significativa frente a aquellas que operan con métodos convencionales. No obstante, la predicción del resultado inmediato de un partido representa solo una dimensión del problema.

La segunda dimensión, igualmente relevante para el negocio, tiene que ver con la comprensión del comportamiento histórico de las selecciones nacionales a lo largo de los distintos torneos mundiales. Identificar grupos de equipos con perfiles de rendimiento similares, detectar patrones de juego recurrentes o reconocer qué características estructurales distinguen a las selecciones con mayor proyección en torneos futuros, son preguntas que no pueden responderse únicamente con un modelo de clasificación. Para abordarlas, se requiere la aplicación de técnicas de aprendizaje no supervisado, como los algoritmos de clustering capaces de agrupar selecciones sin etiquetas predefinidas, basándose exclusivamente en la similitud de sus atributos históricos. Esta perspectiva complementaria permite a los analistas de la casa de apuestas construir narrativas más ricas sobre el torneo: entender qué tipo de selecciones tienden a rendir por encima de las expectativas, cuáles son consistentemente competitivas y cuáles presentan un comportamiento errático e impredecible.

A pesar de la creciente disponibilidad de datos históricos de la Copa Mundial (partidos disputados entre 1930 y 2022, con información sobre resultados, goles, localía y estadísticas básicas de rendimiento) existe un vacío notable en propuestas que integren de manera sistemática y metodológicamente rigurosa los enfoques supervisado y no supervisado sobre esta recopilación de datos. La mayoría de los análisis disponibles se limitan a uno de los dos enfoques o carecen de un marco metodológico estructurado que garantice la reproducibilidad y validez de los resultados. El presente proyecto busca cubrir precisamente ese vacío: ofrecer un modelo dual que no solo prediga resultados, sino que también revele la estructura latente del rendimiento deportivo en el torneo más importante del fútbol mundial, con potencial aplicación directa en contextos de inteligencia competitiva deportiva y análisis de riesgo en la industria de las apuestas.

### **3. Pregunta problema**

¿De qué manera la implementación de modelos de aprendizaje supervisado de clasificación permite predecir los resultados de los encuentros en la Copa Mundial de la FIFA (1930–2022) y cómo el uso de técnicas de agrupamiento no supervisado puede identificar perfiles de rendimiento competitivo que caractericen a las selecciones nacionales a lo largo de la historia?

#### 4. Objetivo general

Desarrollar un sistema de análisis predictivo basado en Machine Learning que, mediante la implementación de un modelo supervisado de clasificación y un modelo no supervisado de agrupamiento, permita predecir el resultado de partidos de la Copa Mundial de la FIFA e identificar patrones de rendimiento entre selecciones nacionales, a partir del análisis del registro histórico del torneo entre 1930 y 2022.

#### 5. Objetivos específicos

1. Explorar y comprender la estructura del dataset histórico de la Copa Mundial de la FIFA (1930–2022), identificando variables relevantes, distribuciones estadísticas y posibles inconsistencias en los datos.
2. Preparar el conjunto de datos mediante procesos de limpieza, transformación y creación de nuevas variables (feature engineering) que potencien la capacidad predictiva de los modelos.
3. Implementar y entrenar un modelo supervisado de clasificación para predecir el resultado de partidos mundialistas (victoria, empate o derrota) con base en la información histórica recolectada.
4. Aplicar un algoritmo de agrupamiento no supervisado sobre el conjunto de selecciones nacionales para identificar perfiles de rendimiento y comportamiento histórico similares a lo largo de los torneos analizados.
5. Evaluar el desempeño de los modelos mediante métricas apropiadas y validar la calidad de los resultados obtenidos.
6. Interpretar y comunicar los patrones identificados por los modelos, relacionando los hallazgos con el contexto del fútbol mundialista y su potencial aplicación en escenarios de análisis deportivo.

#### 6. Metodología propuesta

El desarrollo del proyecto se estructura bajo la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) ampliamente adoptada en proyectos de ciencia de datos por su enfoque iterativo y orientado a resultados, se organiza en seis fases interrelacionadas que permiten transitar de manera ordenada desde la definición del problema hasta la presentación de conclusiones verificables.

1. **Comprensión del negocio:** consiste en contextualizar el problema analítico dentro del dominio de aplicación. En este proyecto, dicha fase implica caracterizar el fenómeno de las predicciones en torneos de fútbol, comprender las variables que históricamente han influido en los resultados de la Copa Mundial y delimitar con precisión los objetivos de los modelos supervisado y no supervisado. Esta etapa sienta las bases conceptuales que orientarán todas las decisiones técnicas posteriores.
2. **Comprensión de los datos:** comprende la carga, inspección y exploración inicial del dataset histórico de partidos mundialistas. Se realizará un análisis exploratorio de datos que incluye la revisión de valores atípicos, análisis de correlaciones y visualización de tendencias temporales. Este proceso permitirá evaluar la calidad del conjunto de datos y determinar el alcance real de la información disponible para el modelado.
3. **Preparación de los datos:** abarca el conjunto de transformaciones necesarias para que los datos sean aptos para el entrenamiento de los modelos. Esto incluye el tratamiento de valores faltantes, la codificación de variables categóricas, la normalización o estandarización de variables numéricas y la ingeniería de características (creación de nuevas variables derivadas como diferencia histórica de rendimiento entre selecciones, promedio de goles por torneo y condición de localía). La calidad de esta fase determinará en gran medida el desempeño de los modelos.
4. **Modelado:** Para el enfoque supervisado se implementará un algoritmo de clasificación (Random Forest o Support Vector Machine) para predecir el resultado de un encuentro (victoria local, empate o victoria visitante). Para el enfoque no supervisado, se aplicará un algoritmo de clustering (K-Means o DBSCAN) sobre el perfil histórico de las selecciones, con el propósito de identificar grupos con características de rendimiento similares a lo largo de los torneos. La selección de hiperparámetros se realizará mediante técnicas de validación cruzada.
5. **Evaluación:** tiene como objetivo medir el desempeño de los modelos desarrollados mediante criterios cuantitativos. Para el modelo supervisado se calcularán la exactitud global (accuracy), el F1-score ponderado, la precisión, el recall y la matriz de confusión, con especial atención al comportamiento del modelo frente a la clase empate, históricamente la más difícil de predecir. Para el modelo no supervisado se utilizarán índices de validez interna como el coeficiente de silueta y el índice Davies-Bouldin para determinar la cohesión y separación de los clústeres obtenidos.
6. **Despliegue:** corresponde a la entrega del documento técnico final, la socialización de los hallazgos y la presentación del pipeline.

## 7. Planteamiento inicial del software

El sistema propuesto consiste en una herramienta analítica orientada al procesamiento de datos históricos de la Copa Mundial de la FIFA, con el propósito de apoyar la toma de decisiones basada en evidencia empírica.

### 7.1 Descripción General del Sistema

Su función principal es integrar, en un único entorno de análisis, los procesos de carga de datos, preprocesamiento, entrenamiento de modelos de Machine Learning y visualización de resultados. El sistema no está diseñado como un producto comercial de predicción en tiempo real, sino como una plataforma académica de análisis retrospectivo con capacidad proyectiva, orientada a demostrar la viabilidad y utilidad de los enfoques supervisado y no supervisado aplicados al dominio del fútbol de alto rendimiento.

El tipo de usuario al que se dirige es el analista de datos o investigador con conocimientos básicos en ciencia de datos y estadística aplicada, que requiere una interfaz o entorno estructurado para ejecutar flujos de análisis sin necesidad de programar desde cero cada componente. El sistema permite al usuario cargar el dataset histórico, configurar los parámetros de los modelos, iniciar el proceso de entrenamiento y consultar los resultados de manera ordenada y reproducible.

El flujo general del sistema sigue una secuencia lógica de tres etapas. En la etapa de entrada, el usuario carga el dataset histórico de partidos mundialistas en formato estructurado. En la etapa de procesamiento, el sistema ejecuta las rutinas de limpieza, transformación y generación de características, tras lo cual entrena los modelos de Random Forest y K-Means. En la etapa de salida, el sistema presenta los resultados de clasificación, los indicadores de evaluación del modelo supervisado y las visualizaciones de los grupos identificados por el modelo no supervisado, junto con una interpretación resumida de los patrones encontrados.

### 7.2 Requerimientos Funcionales

**RF1.** Carga del dataset: el sistema debe permitir la carga del archivo de datos históricos de partidos de la Copa Mundial en formato CSV o Excel y emitir alertas ante inconsistencias detectadas durante la lectura.

**RF2.** Preprocesamiento automático: el sistema debe ejecutar de forma automatizada las rutinas de limpieza de datos, incluyendo el tratamiento de valores faltantes, la eliminación de registros duplicados y la normalización de variables numéricas.

**RF3.** Ingeniería de características: el sistema debe generar las variables derivadas necesarias para el modelado, tales como diferencial histórico de rendimiento entre selecciones o promedio de goles por torneo.

**RF4.** Entrenamiento del modelo supervisado: el sistema debe entrenar un clasificador de Random Forest sobre el conjunto de datos preprocesado, permitiendo al usuario configurar parámetros clave como el número de árboles y la profundidad máxima del modelo.

**RF5.** Ejecución del modelo no supervisado: el sistema debe aplicar el algoritmo K-Means sobre el perfil histórico de las selecciones, permitiendo definir el número de clústeres y visualizando la asignación resultante de cada equipo a su grupo correspondiente.

**RF6.** Evaluación de modelos: el sistema debe calcular y presentar las métricas de desempeño del modelo supervisado (exactitud, F1-score, matriz de confusión) y los índices de validez del modelo no supervisado (coeficiente de silueta, inercia por número de clústeres).

**RF7.** Visualización de resultados: el sistema debe generar gráficos comprensibles para representar los resultados de clasificación, la distribución de clústeres y las tendencias identificadas en los datos históricos.

**RF8.** Exportación de resultados: el sistema debe permitir exportar los resultados del análisis (predicciones, métricas e identificación de clústeres) en formato de archivo estructurado para su comprensión.

## 8. Técnicas de Machine Learning propuestas

El presente proyecto incorpora técnicas de aprendizaje automático tanto supervisado como no supervisado, para analizar los datos históricos de la Copa Mundial de la FIFA

### 8.1 Random Forest para Clasificación Supervisada

Random Forest es un algoritmo de aprendizaje supervisado basado en el principio de ensamble: construye un conjunto de árboles de decisión entrenados de manera independiente sobre subconjuntos aleatorios del conjunto de datos y combina sus predicciones mediante votación mayoritaria. Esta característica le confiere una robustez notable frente al sobreajuste, una limitación frecuente cuando se trabaja con un único árbol de decisión. En el presente proyecto, el modelo recibirá como entrada variables asociadas a cada partido —rendimiento histórico de los equipos involucrados, condición de localía, promedio de goles en torneos anteriores y etapa del torneo— y producirá como salida una de tres etiquetas de clasificación: victoria local, empate o victoria visitante.

El entrenamiento se realizará dividiendo el dataset en un conjunto de entrenamiento y uno de prueba, con una proporción aproximada de 80/20. La selección de hiperparámetros

óptimos —número de estimadores, profundidad máxima del árbol y criterio de partición— se llevará a cabo mediante validación cruzada con k-folds. La elección de Random Forest se justifica por su capacidad de manejar conjuntos de datos con múltiples variables categóricas y numéricas, por su tolerancia a datos ruidosos o con valores atípicos y por la posibilidad de calcular la importancia relativa de cada variable en la predicción, lo que enriquece la interpretación de los resultados desde una perspectiva analítica.

## 8.2 K-Means para Agrupamiento No Supervisado

K-Means es un algoritmo de agrupamiento que divide un conjunto de observaciones en k clústeres, de manera que cada observación sea asignada al clúster cuyo centroide —el promedio de sus miembros— se encuentre más próximo en el espacio de características. El proceso iterativo minimiza la inercia intraclúster, buscando grupos internamente cohesivos y bien diferenciados entre sí. En este proyecto, cada selección nacional será representada como un vector de características construido a partir de su desempeño histórico acumulado: partidos disputados, porcentaje de victorias, diferencia de goles media, promedio de goles anotados y fases alcanzadas en los torneos en los que participó.

La determinación del número óptimo de clústeres se realizará mediante el método del codo, analizando la variación de la inercia en función del número de grupos, complementado con el cálculo del coeficiente de silueta para validar la calidad del agrupamiento obtenido. Se elige K-Means por su eficiencia computacional con conjuntos de datos de tamaño moderado, por su facilidad de interpretación y por ser un algoritmo de referencia ampliamente validado en estudios de análisis deportivo. Su resultado permitirá identificar perfiles de selecciones como potencias consolidadas, equipos de rendimiento intermedio y selecciones con participación irregular, aportando una dimensión descriptiva que complementa las predicciones del modelo supervisado.

## 9. Arquitectura propuesta

El sistema se organiza en cuatro capas funcionales interconectadas que reflejan el flujo lógico del procesamiento de datos: desde la fuente de información hasta la presentación de resultados. Cada capa tiene una responsabilidad y opera sobre los productos generados por la capa anterior, garantizando trazabilidad y modularidad en el proceso analítico.

### 9.1 Capa de Datos

Punto de entrada del sistema y comprende el dataset histórico de partidos de la Copa Mundial de la FIFA (1930–2022). El archivo contiene registros estructurados con información sobre los equipos participantes, los resultados de cada encuentro, el número de goles anotados y la etapa del torneo correspondiente. La responsabilidad de esta capa se limita al almacenamiento y la carga controlada de los datos, así como a la verificación preliminar de su integridad estructural. El dataset actúa como la única fuente de verdad del



sistema y no se modifica durante el proceso; cualquier transformación se realiza sobre copias de trabajo generadas en la capa siguiente.

## 9.2 Capa de Procesamiento

Recibe los datos crudos provenientes de la capa anterior y aplica sobre ellos las rutinas de limpieza, transformación y generación de características. Esta capa ejecuta el tratamiento de valores faltantes, la codificación de variables categóricas, la normalización de variables numéricas y, principalmente, la ingeniería de características: construcción de variables derivadas que representen el rendimiento histórico de cada selección de manera cuantitativa. La salida de esta capa es un conjunto de datos limpio y enriquecido, listo para ser consumido por la capa de modelos. La separación explícita entre datos brutos y datos procesados garantiza que el proceso sea reproducible y auditable.

## 9.3 Capa de Modelos

Contiene los dos componentes centrales del sistema: el modelo supervisado de Random Forest y el modelo no supervisado de K-Means. Ambos reciben como entrada el conjunto de datos procesado, aunque operan sobre subconjuntos distintos: el modelo supervisado utiliza los registros de partidos con sus etiquetas de resultado, mientras que el modelo no supervisado trabaja sobre el perfil agregado de cada selección. Dentro de esta capa se realizan el entrenamiento, la validación cruzada y la evaluación de cada modelo. La capa de modelos expone únicamente sus resultados (predicciones, métricas y asignaciones de clúster) hacia la capa siguiente, sin exponer sus parámetros internos al usuario final.

## 9.4 Capa de Resultados

La capa de resultados centraliza la presentación, visualización e interpretación de los productos generados por la capa de modelos. Incluye las métricas de evaluación del modelo supervisado (exactitud, F1-score, matriz de confusión), los gráficos de distribución de clústeres y sus caracterizaciones descriptivas, así como los reportes exportables para uso académico. Esta capa no realiza transformaciones adicionales sobre los datos: su función es traducir los resultados técnicos en información comprensible y accionable para el analista. La separación entre la lógica de modelado y la presentación de resultados facilita la incorporación de nuevas visualizaciones sin afectar el comportamiento de los modelos.

## 10. Cronograma

| Actividad                                                    | fecha     | Responsable                                                             |
|--------------------------------------------------------------|-----------|-------------------------------------------------------------------------|
| Recolección y carga del dataset histórico de la Copa Mundial | Semana 10 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |
| Análisis exploratorio de datos                               | Semana 10 | - Ronald Samir Molinares Sanabria                                       |

|                                                                    |           |                                                                         |
|--------------------------------------------------------------------|-----------|-------------------------------------------------------------------------|
|                                                                    |           | - María Fernanda Sogamoso González                                      |
| Preprocesamiento de datos                                          | Semana 11 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |
| Desarrollo e implementación del modelo supervisado (Random Forest) | Semana 12 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |
| Desarrollo e implementación del modelo no supervisado (K-Means)    | Semana 12 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |
| Evaluación y ajuste de ambos modelos                               | Semana 13 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |
| Generación de visualizaciones y análisis de resultados             | Semana 13 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |
| Redacción del informe final y preparación de la presentación       | Semana 14 | - Ronald Samir Molinares Sanabria<br>- María Fernanda Sogamoso González |

La semana 10 corresponde a la fase de comprensión del negocio y de los datos. La semana 11 cubre la preparación del conjunto de datos. La semana 12 se destina al desarrollo de ambos modelos de Machine Learning. La semana 13 concentra la evaluación comparativa de modelos y la generación de visualizaciones. La semana 14 es para la consolidación del informe académico final y la preparación de la presentación de resultados.